UNIVERSIDADE FEDERAL DE MATO GROSSO – UFMT
BACHARELADO EM ESTATÍSTICA
MINERAÇÃO DE DADOS
LISTA DE EXERCÍCIOS 1

1.1. A mineração de dados está inserida em um processo mais amplo de descoberta de conhecimento a partir de dados. Com base nessa perspectiva, responda:

a) O que é mineração de dados?

b) Qual a relação entre mineração de dados, Estatística, Aprendizado de Máquina e Bancos de Dados?

c) Descreva as principais etapas do processo de descoberta de conhecimento em bases de dados, indicando o objetivo de cada uma delas.

d) Explique por que a mineração de dados não deve ser entendida apenas como a aplicação de um algoritmo a um conjunto de dados.

1.2. Os dados utilizados em processos de mineração podem apresentar diferentes estruturas e origens. Responda:

a) Diferencie dados estruturados, semiestruturados e não estruturados.

b) Apresente um exemplo de fonte de dados para cada um desses tipos.

c) Explique como o tipo e a estrutura dos dados podem influenciar as etapas de preparação e análise.

1.3. A preparação dos dados constitui uma etapa fundamental do processo de descoberta de conhecimento. Diferencie os seguintes conceitos:

a) Pré-processamento de dados.

b) Transformação de dados.

c) Redução de dados.

Para cada um deles, apresente pelo menos dois exemplos de procedimentos que podem ser realizados.

1.4. Durante o pré-processamento, diferentes problemas relacionados à qualidade dos dados podem ser identificados. Explique como cada uma das situações abaixo pode afetar uma análise de mineração de dados e indique possíveis estratégias para seu tratamento:

a) Registros duplicados.

b) Valores ausentes.

c) Valores atípicos.

d) Inconsistências na representação de categorias.

e) Inconsistências de formato ou tipo das variáveis.

1.5. O conceito de *tidy data* estabelece uma forma padronizada de organização dos dados para análise. Responda:

a) O que caracteriza um conjunto de dados no formato *tidy*?

b) Qual deve ser a relação entre variáveis, observações e valores na organização da tabela?

c) Por que essa estrutura facilita as etapas posteriores de manipulação, visualização e análise dos dados?

1.6. Na construção de uma base analítica, diferentes operações de manipulação podem ser necessárias. Explique a finalidade das seguintes operações:

a) Selecionar variáveis.

b) Filtrar observações.

c) Ordenar observações.

d) Criar ou transformar variáveis.

e) Agrupar e resumir dados.

f) Identificar e remover registros duplicados.

g) Concatenar bases de dados.

h) Juntar ou conciliar bases de dados.

Explique também a diferença entre **concatenar** e **juntar** bases de dados.

1.7. A visualização de dados pode ser utilizada em diferentes momentos do processo de descoberta de conhecimento. Responda:

a) Em quais etapas desse processo a visualização pode ser utilizada?

b) Qual o papel da visualização durante a exploração e preparação dos dados?

c) Como a visualização pode auxiliar na interpretação e comunicação dos resultados obtidos?

1.8. A construção de gráficos pode ser compreendida a partir da chamada **Gramática dos Gráficos**. Explique esse conceito e descreva o papel dos seguintes componentes:

a) Dados.

b) Mapeamentos estéticos (*aesthetics*).

c) Objetos geométricos (*geoms*).

d) Facetas.

e) Escalas.

f) Sistema de coordenadas.

g) Temas.

Explique, ainda, por que uma mesma base de dados pode resultar em diferentes representações gráficas dependendo das escolhas realizadas nesses componentes.

1.9. O banco de dados **PRFocorrencias** contém informações sobre acidentes registrados em rodovias federais no ano de **2025**. Consulte o **Dicionário de Dados** para conhecer a descrição e o significado das variáveis e realize as tarefas a seguir.

a) Realize uma inspeção inicial do banco de dados, identificando o número de observações e variáveis, os nomes das variáveis e seus respectivos tipos.

b) Filtre o banco de dados para manter somente as ocorrências registradas no estado de **Mato Grosso (MT)**. Utilize esse subconjunto nas análises seguintes.

c) Para Mato Grosso, obtenha o número total de acidentes, pessoas envolvidas, feridos leves, feridos graves, mortos e veículos envolvidos.

d) Agrupe os dados por município e obtenha o número de acidentes, feridos e mortos. Apresente os 10 municípios com maior número de acidentes.

e) Analise a distribuição dos acidentes segundo o dia da semana, fase do dia e classificação do acidente, apresentando as frequências absoluta e relativa.

f) Identifique as 10 causas de acidentes mais frequentes e as 10 causas associadas ao maior número de mortes. Compare os resultados.

g) Construa pelo menos três visualizações gráficas para representar aspectos relevantes identificados nas análises anteriores. Para cada visualização, apresente uma breve interpretação dos resultados.

h) Com base nos resultados obtidos, descreva os principais padrões observados nos acidentes ocorridos em Mato Grosso.

1.10. O banco de dados **Voo_ANAC_2025** contém informações sobre os voos regulares registrados pela Agência Nacional de Aviação Civil (ANAC) no ano de **2025**. Consulte o **Dicionário de Dados** para conhecer a descrição e o significado das variáveis e realize as tarefas a seguir.

a) Realize uma inspeção inicial do banco de dados, identificando o número de observações e variáveis e os respectivos tipos.

b) Considerando que o código ICAO do Aeroporto Internacional Marechal Rondon é **SBCY**, filtre os registros correspondentes aos voos que tiveram Cuiabá como origem ou destino. Utilize esse subconjunto nas análises seguintes.

c) Crie uma variável que identifique se cada registro corresponde a um voo com **saída de Cuiabá** ou **chegada a Cuiabá**.

d) A partir das informações de data e horário disponíveis no banco, crie variáveis correspondentes ao mês, dia da semana e hora do voo.

e) Compare os horários previstos e realizados de partida e chegada. Crie variáveis, expressas em minutos, que permitam identificar atrasos e antecipações dos voos.

f) Para os voos relacionados a Cuiabá, obtenha:

   i) o número de voos por empresa aérea;
   ii) o número de voos por mês;
   iii) os principais aeródromos de origem dos voos que chegam a Cuiabá;
   iv) os principais aeródromos de destino dos voos que partem de Cuiabá;
   v) a distribuição dos voos segundo a situação registrada;
   vi) medidas-resumo para as diferenças entre os horários previstos e realizados de partida e chegada.

g) Investigue se o comportamento das diferenças entre os horários previstos e realizados varia de acordo com a **empresa aérea** e o **mês do ano**. Apresente medidas que permitam realizar essas comparações.

h) Construa pelo menos três visualizações gráficas que representem aspectos relevantes identificados nas análises anteriores. Para cada visualização, apresente uma breve interpretação dos resultados.

1.11. O banco de dados **Covid** contém informações sobre a evolução da COVID-19 nos municípios brasileiros ao longo das semanas epidemiológicas, bem como indicadores relacionados à estrutura de atendimento à saúde. Consulte o **Dicionário de Dados** e realize as tarefas a seguir.

a) Selecione apenas os municípios dos estados de **Mato Grosso (MT)**, **Goiás (GO)** e **Mato Grosso do Sul (MS)**. Utilize esse subconjunto nas análises seguintes.

b) Identifique quais variáveis apresentam variação ao longo das semanas epidemiológicas e quais representam características estruturais dos municípios.

c) Construa uma nova base contendo uma única observação por município e os respectivos indicadores de estrutura de atendimento à saúde.

d) Analise a variabilidade dos indicadores de estrutura de atendimento à saúde, identificando variáveis com variância nula ou reduzida e avaliando sua permanência nas análises posteriores.

e) Analise as correlações entre os indicadores de estrutura de atendimento à saúde e identifique possíveis situações de redundância entre as variáveis.

f) Realize a padronização dos indicadores selecionados e aplique a Análise de Componentes Principais (PCA). Determine o número de componentes a serem retidos e interprete-os com base na contribuição das variáveis originais.

g) Utilize representações gráficas adequadas para comparar os municípios de MT, GO e MS no espaço definido pelos componentes principais e interprete os principais padrões observados.